

XI PROPOSAL SKRIPSI

Formatted: Centered

**PRODUK ANALISIS DAN REKOMENDASI PADA PLATFORM E-COMMERCE
(SHOPEE) DENGAN MENGGUNAKAN RAG**

TUGAS AKHIR

**UNTUK MEMENUHI SEBAGIAN DARI SYARAT-SYARAT
GUNA MENCAPAI GELAR SARJANA TEKNIK INFORMATIKA**



NIM : 2210101024

NAMA : Noven Austin

PROGRAM STUDI TEKNIK INFORMATIKA

UNIVERSITAS PRADITA

JAKARTA

2025

DAFTAR ISI

Formatted: Font: (Default) +Body (Calibri)

BAB I	3
1.1 Latar Belakang	3
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	5
1.4.1 Manfaat Subjektif	5
1.4.2 Manfaat Objektif	6
1.5 Ruang Lingkup Penelitian	6
1.6 Metode Penelitian	6
1.7 Sistematika Penulisan	7
BAB II	8
2.1 Kerangka Teoritis	8
2.1.1 Chatbot	8
2.1.2 Analisis Sentimen pada E-commerce	9
2.1.3 Sistem Rekomendasi Berbasis Ulasan	9
2.2 Tinjauan Teoritis	9
2.2.1 Natural Language Processing (NLP)	9
2.2.2 Retrieval-Augmented Generation (RAG)	10
2.2.3 Chunking (Adaptive)	11
2.2.4 Embedding	11
2.2.5 Large Language Models (LLM)	12
2.3 Studi Preseden	13
BAB III	17
TINJAUAN PUSTAKA	21

BAB I

PENDAHULUAN

1.1 Latar Belakang

E-commerce di Asia Tenggara telah berkembang pesat dalam beberapa tahun terakhir, dengan Shopee muncul sebagai platform dominan. Data survei menunjukkan bahwa Shopee menjadi *marketplace* paling sering dikunjungi di Indonesia, meraih angka sebesar 53,22% pada tahun 2025 sebagai toko online yang paling sering diakses. Perkembangan sebesar 11,57% dari tahun sebelumnya dan faktor kompetisi terdekat hanya berada di angka 27,37% (Tiktok Shop) membuktikan bahwa Shopee merupakan salah satu *marketplace e-commerce* terbesar dalam Indonesia [1]. Peningkatan masif aktivitas belanja daring ini sejalan dengan ledakan volume ulasan produk yang dihasilkan konsumen.

-Sebuah survei dilakukan Zhong-Gang et al. mengungkapkan hampir 60% konsumen menjelajahi ulasan produk online setidaknya sekali seminggu dan 93% merasa bahwa ulasan tersebut membantu mereka dalam akurasi keputusan pembelian [2]. Ulasan pelanggan terbukti menjadi sumber informasi yang sangat berpengaruh, membantu konsumen memahami pengalaman pengguna lain dan membangun kepercayaan terhadap produk [3]. Bagi pelaku bisnis, umpan balik ini bernilai krusial, namun juga memiliki risiko tinggi jika diabaikan. Riset empiris oleh [4] menunjukkan dampak fatal dari ulasan negatif, keberadaan hanya satu ulasan negatif di dalam produk dapat menurunkan probabilitas pembelian hingga 51,4%. Hal ini menegaskan bahwa ulasan negatif yang diabaikan dapat berdampak pada reputasi dan pendapatan toko.

Namun, ledakan jumlah ulasan menghadirkan tantangan tersendiri. Informasi yang tersedia melebihi kapasitas dimana manusia dapat memprosesnya secara manual [3]. Mayoritas data ini, sekitar 80% hingga 90% dari total data, merupakan data tidak terstruktur yang sulit dikelola [5]. Sementara itu, rata-rata kemampuan kognitif manusia dalam kecepatan membaca hanya berkisar 238 kata per menit. Artinya, ribuan ulasan akan membuat penjual kewalahan dalam menyaring informasi yang relevan.

Untuk mengatasi masalah kelebihan informasi ini, teknologi Natural Language Processing (NLP) telah banyak diterapkan, khususnya dalam bentuk peringkasan dan analisis sentimen otomatis. Meskipun metode ini efektif dalam mengklasifikasikan opini menjadi positif atau negatif, tetapi pendekatan ini memiliki keterbatasan dalam memahami konteks yang kompleks atau menjawab pertanyaan spesifik dari pengguna. Pelaku bisnis membutuhkan lebih dari sekadar label sentimen, mereka memerlukan ringkasan yang informatif atau jawaban

Formatted: Centered, Space After: 0 pt, Line spacing: 1,5 lines

Formatted: Space After: 0 pt, Line spacing: 1,5 lines

atas pertanyaan spesifik terkait performa produk yang sering kali tersembunyi dalam tumpukan ulasan.

Perkembangan teknologi *Large Language Models* (LLM) menawarkan kemampuan generatif yang mampu memahami dan merangkum teks dengan cara yang lebih alami layaknya manusia. Namun, LLM memiliki kelemahan berupa risiko “halusinasi” atau memberi informasi yang tidak sesuai fakta, terutama ketika tidak memiliki akses ke data terkini. Oleh karena itu, diperlukan pendekatan yang menggabungkan kemampuan generatif LLM dengan akurasi pencarian data faktual. Pendekatan ini dikenal sebagai *Retrieval-Augmented Generation* (RAG).

Konsep RAG memungkinkan sistem untuk mengambil informasi relevan dari ulasan produk secara *real-time* dan menggunakannya sebagai dasar untuk menghasilkan analisis serta rekomendasi yang akurat. Dengan menerapkan metode ini pada platform Shopee, diharapkan dapat tercipta sistem cerdas yang tidak hanya mampu merangkum ribuan ulasan secara otomatis, tetapi juga memberikan rekomendasi produk yang dipersonalisasi berdasarkan preferensi pengguna dan wawasan faktual dari ulasan yang ada.

1.2 Rumusan Masalah

Dalam era digital saat ini, volume ulasan yang sangat besar pada platform e-commerce seperti Shopee menjadikan proses pengambilan keputusan dan evaluasi produk semakin kompleks, baik bagi pembeli maupun pemilik toko. Oleh karena itu, diperlukan pendekatan berbasis teknologi yang mampu menyaring, menganalisis, dan menyajikan informasi dari ulasan secara otomatis, ringkas, dan bermanfaat. Penelitian ini merumuskan tiga permasalahan utama:

1. Bagaimana merancang dan membangun arsitektur sistem Retrieval-Augmented Generation (RAG) untuk menganalisis ulasan produk pada platform Shopee?
2. Bagaimana metode *retrieval* dan model bahasa besar (LLM) dapat diimplementasikan dalam sistem untuk meningkatkan kualitas analisis dan rekomendasi ulasan?
3. Bagaimana model besar bahasa (LLM) dapat diimplementasikan dalam sistem untuk meningkatkan kualitas analisis dan rekomendasi ulasan?
3. Bagaimana mengevaluasi efektivitas sistem RAG dalam menghasilkan analisis dan rekomendasi ulasan produk berdasarkan kinerja *retrieval* dan model generatif yang digunakan?

1.3 Tujuan Penelitian

Formatted: Space After: 0 pt, Line spacing: 1,5 lines

Formatted: Space After: 0 pt, Line spacing: 1,5 lines

Penelitian ini bertujuan untuk merancang dan mengimplementasikan prototipe sistem yang mengintegrasikan teknik RAG untuk merangkum serta menganalisis ulasan produk dari Shopee. Sasaran dari penelitian ini adalah sebagai berikut:

1. Merancang arsitektur sistem Retrieval-Augmented Generation (RAG) yang mengintegrasikan komponen retrieval untuk pencarian konteks relevan dan *generation* berbasis *Large Language Model* (LLM) dalam satu *pipeline* guna menghasilkan analisis dan rekomendasi ulasan produk Shopee yang akurat dan kontekstual.
2. Menerapkan metode *retrieval* dan model LLM untuk mengoptimalkan proses pengambilan informasi serta generasi teks agar sistem mampu memahami konteks ulasan pengguna dan menghasilkan ringkasan serta rekomendasi yang relevan.
3. Mengevaluasi performa sistem RAG secara menyeluruh dengan mengukur efektivitas modul *retrieval* dan kualitas keluaran generatif menggunakan metrik yang menilai presisi konteks, recall konteks, relevansi jawaban, dan kesetiaan.

Formatted: Line spacing: 1,5 lines

3.

1.4 Manfaat Penelitian

Formatted: Space After: 0 pt, Line spacing: 1,5 lines, No bullets or numbering

1.4.1 Manfaat Subjektif

Formatted: Heading 3, Left, Indent: First line: 1,27 cm

Penelitian ini memberikan manfaat bagi penelitian untuk memperdalam pengetahuan dan pemahaman dalam bidang *Natural Language Processing (NLP)*, khususnya pada topik *Retrieval-Augmented Generation (RAG)* yang menggabungkan kemampuan *retrieval-based learning* dan *generative model*. Melalui penelitian ini, peneliti dapat mengasah keterampilan dalam merancang, mengimplementasikan, serta mengevaluasi model *Large Language Model (LLM)* yang mampu menganalisis dan menyaring ulasan produk secara otomatis. Selain itu, penelitian ini juga memperluas wawasan peneliti terhadap perkembangan teknologi kecerdasan buatan yang dapat dimanfaatkan untuk meningkatkan pengalaman pengguna di sektor *e-commerce*. Penelitian ini diharapkan dapat memberikan kontribusi baik dari sisi akademik maupun praktis. Dari segi akademik, penelitian ini memperkaya khazanah kajian di bidang pemrosesan bahasa alami dan sistem rekomendasi berbasis LLM, khususnya dalam konteks ulasan *e-commerce* berbahasa Indonesia. Selain itu, pendekatan penggunaan dataset lokal dan pengujian model generatif baru menjadi nilai tambah dalam aspek orisinalitas. Dari sisi praktis, sistem yang dikembangkan berpotensi menjadi solusi aplikatif bagi pemilik toko di Shopee dalam mengidentifikasi

kebutuhan dan keluhan pelanggan secara efisien, serta membantu calon pembeli mengambil keputusan berdasarkan ringkasan ulasan yang terstruktur dan informatif.

1.4.2 Manfaat Objektif

Dari sisi praktis dan akademik, penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Menyediakan solusi berbasis kecerdasan buatan yang mampu merangkum dan menganalisis ulasan produk secara otomatis sehingga membantu konsumen dalam mengambil keputusan pembelian yang lebih cepat dan tepat.
2. Memberikan kontribusi terhadap pengembangan sistem rekomendasi produk yang lebih cerdas dan relevan, khususnya untuk platform e-commerce Shopee.
3. Menjadi referensi akademik dan dasar penelitian lanjutan di bidang *Retrieval-Augmented Generation*, *text summarization*, dan *sentiment analysis* berbahasa Indonesia.

1.5 Ruang Lingkup Penelitian

Penelitian ini berfokus pada perancangan dan implementasi prototipe sistem berbasis *Retrieval-Augmented Generation (RAG)* yang digunakan untuk menganalisis dan memberikan rekomendasi berdasarkan ulasan produk e-commerce Shopee.

Ruang lingkup penelitian mencakup:

1. Pengumpulan dan pengolahan dataset ulasan produk berbahasa Indonesia dari platform Shopee.
2. Penerapan model RAG yang mengintegrasikan *retrieval module* (untuk pencarian konteks relevan) dan *generative module* (untuk menghasilkan ringkasan dan rekomendasi).
3. Evaluasi kinerja sistem berdasarkan metrik akurasi, relevansi hasil, dan kualitas keluaran generatif.
4. Penelitian ini tidak mencakup aspek implementasi penuh dalam skala industri atau integrasi langsung dengan sistem Shopee, melainkan terbatas pada tahap pengujian prototipe berbasis data yang dikumpulkan.

1.6 Metode Penelitian

Metode penelitian yang digunakan dalam penyusunan tugas akhir ini mencakup beberapa tahapan sebagai berikut:

1. Pengumpulan Data
 - a. Studi literatur, dilakukan untuk memahami secara mendalam konsep dan cara kerja *Retrieval-Augmented Generation (RAG)*, termasuk arsitektur

Formatted: Font: (Default) Times New Roman

Formatted: Indent: First line: 0 cm, Space After: 0 pt, Line spacing: 1,5 lines

Formatted: Justified

Formatted: List Paragraph, Justified, Numbered + Level: 1 + Numbering Style: 1, 2, 3, ... + Start at: 1 + Alignment: Left + Aligned at: 0,63 cm + Indent at: 1,27

Formatted: Justified

Formatted: List Paragraph, Justified, Numbered + Level: 1 + Numbering Style: 1, 2, 3, ... + Start at: 1 + Alignment: Left + Aligned at: 0,63 cm + Indent at: 1,27

Formatted: Heading 2 Char

sistemnya, macam-macam metode *retrieval*, teknik *embedding* yang relevan, model bahasa besar (LLM) yang digunakan, serta metrik evaluasi.

- b. Dataset dikumpulkan dengan menggunakan API Shopee yang terhubung dengan toko pribadi untuk memperoleh data ulasan produk secara langsung. Data yang dikumpulkan mencakup nama pembeli, nilai rating, tanggal ulasan, dan teks ulasan itu sendiri. Data ini menjadi basis korpus yang akan digunakan dalam tahap *retrieval*.

2. Analisis dan Perancangan

- a. Melakukan analisis terhadap metode *retrieval* dan *embedding*, yang akan digunakan untuk mengambil informasi dari korpus,
- b. Analisis terhadap dataset dilakukan termasuk proses pembersihan data (*data cleaning*), pra-pemrosesan data (*data preprocessing*) untuk membuat sebuah korpus yang digunakan sebagai konteks tambahan model bahasa besar (LLM)
- c. Merancang model RAG yang menggabungkan *retrieval* dan *generation* untuk menghasilkan rekomendasi dan ringkasan yang sesuai dengan konteks.

3. Implementasi

- a. Mengimplementasikan sistem RAG dengan menggunakan dataset yang telah dibuat. Sistem ini akan diuji dalam pembuatan rekomendasi dan ringkasan ulasan produk.
- b. Melakukan evaluasi terhadap performa metode *retrieval* dan model bahasa besar (LLM) dalam menghasilkan jawaban yang relevan, informatif, dan konsisten dengan konteks pertanyaan.

Formatted: Justified

1.7 Sistematika Penulisan

Formatted: Heading 2 Char

Penulisan laporan tugas akhir ini disusun dalam beberapa bab yang terbagi sebagai berikut:

BAB I – Pendahuluan

Menjelaskan latar belakang masalah, rumusan masalah, tujuan, manfaat, ruang lingkup, metode penelitian, serta sistematika penulisan laporan.

BAB II – Tinjauan Pustaka

Berisi Kajian teori yang mendasari penelitian, termasuk konsep e-commerce, *Retrieval-Augmented Generation*, *Natural Language Processing (NLP)*, *summarization*, dan *sentiment analysis*, serta penelitian terdahulu yang relevan.

BAB III – Metodologi Penelitian

Menguraikan langkah-langkah penelitian secara terperinci, mulai dari pengumpulan data, perancangan sistem, hingga implementasi model dan pengujian.

BAB IV – Hasil dan Pembahasan

Menjelaskan hasil implementasi, performat sistem, serta analisis hasil uji terhadap efektivitas model RAG dalam mengashilkan ringkasan dan rekomendasi ulasan.

BAB V – Kesimpulan dan Saran

Menyajikan kesimpulan dari hasil penelitian dan memberikan sarann untuk pengembangan lebih lanjut.

BAB II TINJAUAN PUSTAKA

2.1 Kerangka Teoritis

2.1.1 Chatbot

Teknologi antarmuka percakapan atau *chatbot* telah berevolusi dari sistem berbasis aturan yang kaku dan tidak natural menjadi agen cerdas berbasis *Generative AI*. Pada fase awal, *chatbot e-commerce* bekerja dengan mencocokkan kata kunci pengguna terhadap basis data jawaban statis. Pendekatan ini sering kali gagal menangani pertanyaann kompleks atau tidak bisa menjawab dengan konteks data terbaru. Hal ini membuat interaksi dengan *chatbot* terasa kaku dan sering kali membuat pengguna frustasi yang mengharapkan jawaban yang lebih manusiawi dan informatif.

Kemunculan *Large Language Models* (LLM) telah merevolusi bidang ini dengan kemampuan dalam menghasilkan teks generatif yang natural dan menyerupai tutur bahasa manusia. Namun, seperti hasil dari survei yang dilakukan oleh ~~tsitasi~~ [6], terlihat bahwa model generatif murni memiliki kelemahan berupa halusinasi, yaitu menghasilkkan informasi dengan fakta yang salah dan ketidakmampuan untuk

Formatted: Centered, Space After: 0 pt, Line spacing: 1,5 lines

mengakses data secara *real-time*. Oleh karena itu, tren penelitian bergeser menuju arsitektur hibrida yang menggabungkan kemampuan generatif dengan mekanisme pencarian fakta (*retrieval*).

2.1.2 Analisis Sentimen pada E-commerce

Sebelum dominasi model generatif, pendekatan utama dalam pengolahan ulasan produk adalah melalui klasifikasi sentimen antara positif, netral, atau negatif dan peringkasan ekstraktif. Penelitian terdahulu, seperti sistem SEOpinion yang dikembangkan oleh [3] berfokus pada peringkasan opini berbasis aspek untuk membantu pengguna membandingkan fitur spesifik suatu produk. Dalam konteks bahasa Indonesia, [7] membuktikan bahwa model IndoBERT yang mampu mengklasifikasikan sentimen ulasan Shopee dengan akurasi mencapai 93%. Masih dalam topik yang sama, [8] mengusulkan model hibrida *Deep Learning* dengan seleksi fitur inovatif yang semakin meningkatkan presisi analisis.

Metode klasifikasi tersebut sangat andal dalam memberikan statistik kepuasan pengguna (positif vs negatif), namun pendekatan ini memiliki keterbatasan. Model klasifikasi bersifat statis dan hanya menghasilkan label kategori, sehingga tidak mampu menjawab pertanyaan kausalitas atau pertanyaan spesifik dari pengguna. Penelitian oleh [9] mencoba menjembatani ini dengan peringkasan terpolarisasi yang memisahkan poin pro dan kontra, namun solusi ini masih belum memberikan interaktivitas tanya-jawab yang diinginkan dalam sistem modern.

2.1.3 Sistem Rekomendasi Berbasis Ulasan

Sistem rekomendasi tradisional, seperti *Collaborative Filtering*, bekerja dengan memprediksi preferensi pengguna berdasarkan pola interaksi masa lalu. Namun, metode ini sering mengabaikan kekayaan informasi semantik yang terkandung dalam teks ulasan. Riset terbaru mulai mengeksplorasi analisis sentimen ke dalam algoritma rekomendasi dapat meningkatkan relevansi saran produk secara signifikan, karena sistem dapat memahami alasan di balik rating yang ditinggalkan pengguna [10].

Tren penelitian terkini juga bergerak menuju pemanfaatan *Large Language Models* (LLM). [11] memperkenalkan kerangka kerja *Knowledge Graph Retrieval-Augmented Generation* (K-RagRec) yang dirancang khusus untuk sistem rekomendasi. Penelitian mereka mengungkapkan bahwa menggabungkan LLM dengan *knowledge graph* terstruktur mampu mengurangi halusinasi model dan memberikan rekomendasi yang didukung oleh alasan faktual kuat dan yang dapat dijelaskan. Temuan ini menjadi dasar bagi penelitian ini untuk memanfaatkan ulasan sebagai basis pengetahuan utama dalam memberikan rekomendasi produk.

2.2 Tinjauan Teoritis

2.2.1 Natural Language Processing (NLP)

Natural Language Processing (NLP) merupakan cabang ilmu kecerdasan buatan yang menjembatani komunikasi antara manusia dan komputer, memungkinkan mesin untuk memahami bahasa manusia. Dalam konteks *e-commerce* di Indonesia, NLP menghadapi tantangan berupa variasi linguistik yang tinggi, termasuk penggunaan bahasa gaul (*slang*), singkatan tidak baku, dan campuran antara Bahasa Indonesia, Bahasa Inggris, dan bahasa daerah. Kompleksitas ini menuntut metode pemrosesan yang lebih canggih daripada sekadar analisis.

Untuk mengatasi masalah itu, sebuah riset dilakukan oleh [12] telah meletakkan fondasi penting melalui pengembangan *IndoNLU Benchmark*, sebuah kerangka evaluasi untuk bahasa Indonesia. Hasil riset ini menyediakan model bahasa *pre-trained* seperti IndoBERT yang telah dilatih pada korpus besar data teks Indonesia. Kehadiran model ini memungkinkan sistem untuk menangkap nuansa kontekstual dan semantik lokal dengan jauh lebih baik dibandingkan model multilingual generik.

2.2.2 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) adalah suatu *framework* yang menggabungkan model *language generation* dengan modul *retrieval* pengetahuan eksternal. Ide utama RAG ialah memperkaya kemampuan generatif model bahasa besar dengan informasi kontekstual yang diambil dari sumber luar secara dinamis, sehingga keluaran yang dihasilkan lebih akurat dan faktual. Teknik ini muncul sebagai solusi atas keterbatasan LLM yang cenderung halusinasi atau tidak mengetahui informasi terbaru di luar data latihnya. Dalam skema RAG, ketika model menerima sebuah kueri, modul *retrieval* akan menelusuri korpus eksternal untuk mengambil potongan informasi relevan. Informasi yang berhasil diambil kemudian diberikan sebagai konteks tambahan bagi model generatif dalam menghasilkan jawaban atau ringkasan. Dengan demikian, output yang dihasilkan model lebih berlandaskan fakta dan *up-to-date*.

RAG telah terbukti efektif meningkatkan performa pada berbagai tugas *knowledge-intensive*, contohnya pada question answering berbasis pengetahuan. Dalam domain sistem rekomendasi, RAG memungkinkan model memberikan rekomendasi yang lebih tepat dengan memanfaatkan pengetahuan produk/penilaian terbaru. Sebagai ilustrasi, *LLM-based recommender system* tradisional dapat mengalami kendala ketika diminta merekomendasikan film terbaru yang tidak ada dalam data latihnya, atau bisa saja “mengarang” rekomendasi yang keliru. Dengan pendekatan RAG, model akan melakukan *retrieve* informasi film terbaru dan menggunakan informasi tersebut untuk menghasilkan rekomendasi, sehingga mengurangi kesalahan akibat pengetahuan usang.

Salah satu pengembangan terkini RAG adalah integrasinya dengan knowledge graph. Wang *et al.* (2025) mengusulkan kerangka *Knowledge Graph Retrieval-Augmented Generation* khusus untuk sistem rekomendasi berbasis LLM [11]. Pendekatan tersebut (disebut K-RagRec) memanfaatkan struktur graf pengetahuan, modul *retrieval* tidak hanya mengambil fakta lepas, tetapi juga sub-graf terstruktur yang memuat entitas dan hubungan relevan. Informasi terstruktur ini kemudian diintegrasikan dalam proses generatif LLM untuk menghasilkan rekomendasi. Hasil

eksperimen menunjukkan bahwa memasukkan pengetahuan terstruktur dari *knowledge graph* mampu mengatasi noise dan meningkatkan akurasi rekomendasi dibanding RAG konvensional [11]. Secara keseluruhan, RAG merupakan konsep penting yang menjembatani *information retrieval* dan *text generation*, dan menjadi landasan dalam penelitian ini untuk memastikan bahwa ringkasan atau rekomendasi yang dihasilkan model memiliki dasar informasi yang kuat dan aktual, khususnya dalam konteks ulasan produk yang informasinya selalu berkembang.

2.2.3 Chunking (Adaptive)

Chunking atau pemotongan teks adalah tahapan pra-pemrosesan yang memecah dokumen panjang menjadi potongan teks yang lebih kecil agar sesuai dengan jendela konteks (*context window*) model. Namun, metode pemotongan standar yang hanya berbasis jumlah karakter sering kali memutuskan kalimat di tengah jalan atau memisahkan informasi yang saling berkaitan, sehingga merusak makna semantik yang terkandung dalam kalimat. [13] menemukan bahwa strategi pengelolaan token yang buruk dapat menurunkan kinerja sistem secara signifikan.

Sebagai solusi, penelitian ini mencoba untuk mengadopsi teori *Adaptive Chunking* dengan pendekatan logika spasial-temporal. Berbeda dengan pemotongan teks yang tradisional, metode ini memperlakukan data secara dinamis, ulasan pendek yang memiliki sentimen serupa akan dikelompokkan untuk mempertahankan densitas informasi, sedangkan ulasan panjang dipotong dengan teknik *Context Injection*. Teknik ini menyisipkan metadata produk di awal setiap potongan teks. Tujuannya adalah memastikan bahwa setiap potongan ulasan tetap memiliki konteks yang utuh, sehingga mesin tidak kehilangan referensi subjek saat mengambil potongan teks tersebut nantinya.

2.2.4 Embedding

Istilah *word embedding* merujuk pada teknik yang memetakan kata atau frasa ke vektor nyata berdimensi tetap yang merepresentasikan makna kata tersebut dalam ruang vektor berisi pola hubungan semantik. Dalam ruang vektor ini, kedekatan jarak antar vektor mencerminkan tingkat kemiripan makna semantiknya, bukan sekadar kesamaan kata. Hal tersebut dilakukan untuk memungkinkan sistem melakukan pencarian semantik, di mana mesin dapat memahami bahwa kata dengan ejaan yang berbeda bisa memiliki makna yang berdekatan.

Dengan pembelajaran dari korpus bahasa, *word embeddings* mampu menangkap kemiripan semantik antar kata. Keunggulan ini membuat embedding berbasis kata berhasil mengatasi kendala pendekatan leksikal murni yang hanya mengandalkan *string matching* [14]. Namun, *embedding* tradisional bersifat statik, artinya setiap kata memiliki vektor yang sama terlepas dari konteks kalimatnya. Keterbatasan ini mengabaikan fakta bahwa banyak kata bersifat polisemi (memiliki makna berbeda pada konteks berbeda). Sebagai solusi, *contextual embedding* dikembangkan yang menghasilkan representasi vektor sebuah kata bergantung pada

konteks kalimatnya, sehingga makna spesifik kata tersebut tercermin menyesuaikan kalimat [14]. Dibanding embedding statik, model kontekstual secara signifikan memperbaiki relevansi hasil pencarian karena kemampuannya untuk memahami makna kueri dengan dokumen secara lebih tepat. Dalam sistem RAG, penggunaan embedding yang kontekstual berperan penting dalam peningkatan relevansi.

Kualitas sistem *retrieval* dalam RAG sangat bergantung pada model *embedding* yang digunakan. [14] menunjukkan bahwa *Contextual Word Embeddings* jauh lebih unggul dibandingkan metode leksikal tradisional dalam menangkap nuansa data teks yang kompleks. Dalam penelitian ini, teori tersebut diterapkan melalui penggunaan model (BERT dan E5) yang dilatih dengan metode *contrastive learning*. Model ini dioptimalkan untuk memetakan ulasan berbahasa campuran ke dalam ruang vektor yang akurat, memastikan relevansi tinggi antara pertanyaan pengguna dan hasil pencarian.

2.2.5 Large Language Models (LLM)

Large Language Models (LLM) merupakan evolusi terkini dalam bidang pemrosesan bahasa alami (NLP) yang merujuk pada model pembelajaran mendalam (*deep learning*) berskala masif menggunakan miliaran parameter pada korpus teks yang sangat besar. Berbeda dengan model bahasa tradisional yang terbatas pada tugas spesifik, LLM memiliki kemampuan generalisasi yang memungkinkan model untuk melakukan berbagai tugas tanpa pelatihan ulang yang ekstensif [15].

Arsitektur mayoritas LLM modern (seri GPT, LLaMA) adalah arsitektur *Transformer*. Komponen kunci dari arsitektur ini adalah mekanisme *self-attention*, yang memungkinkan model untuk menimbang penting setiap kata dalam sebuah kalimat terhadap kata lainnya, terlepas dari letak kata dalam kalimat. Berkat mekanisme ini, LLM mampu menangkap konteks jangka panjang dan nuansa semantik yang sering kali terlewatkan oleh model sekuensial sebelumnya [15].

Dalam konteks *e-commerce*, penerapan LLM menawarkan keunggulan signifikan dibandingkan metode analisis sentimen konvensional. Penelitian oleh [16] menunjukkan bahwa LLM mampu memahami ulasan pelanggan yang mengandung sarkasme, bahasa gaul, atau sentimen campuran dengan akurasi yang lebih ditinggi dibanding metode statistik klasik. Kemampuan generatif dari LLM juga memungkinkan sistem untuk tidak hanya mengklasifikasi sentimen, melainkan memberikan penjelasan kausal mengapa pelanggan merasa demikian, memberikan wawasan yang lebih dalam bagi pemilik bisnis [16].

Namun, meskipun memiliki kemampuan generatif yang kuat, LLM memiliki keterbatasan, yaitu risiko halusinasi atau kecenderungan model untuk menghasilkan informasi yang tidak sesuai dengan fakta. Selain itu, pengetahuan terbatas pada data saat model tersebut terlatih (*knowledge cutoff*), sehingga model tidak mengetahui informasi produk atau harga terbaru secara *real-time*. Keterbatasan inilah yang mendasari penelitian ini untuk integrasi LLM dengan metode *Retrieval-Augmented*

Generation (RAG), guna memberi konteks tambahan supaya hasil generatif yang dihasilkan tetap akurat [17].

2.3 Studi Preseden

Penelitian-penelitian terdahulu telah banyak mengeksplorasi pendekatan berbasis pembelajaran mendalam untuk mendukung tugas pemahaman bahasa alami, khususnya pada sistem pencarian informasi dan analisis sentimen. Studi-studi ini memberikan fondasi penting bagi pengembangan metode Retrieval-Augmented Generation (RAG), serta implementasi model bahasa seperti IndoBERT untuk konteks berbahasa Indonesia. Tabel berikut merangkum penelitian terdahulu yang menjadi basis dari penelitian ini.

Judul	Tujuan Penelitian	Metode yang digunakan	Hasil Utama / Findings
Knowledge Graph Retrieval-Augmented Generation for LLM-based Recommendation	Meningkatkan akurasi rekomendasi berbasis LLM dan mengurangi halusinasi dengan memanfaatkan <i>Knowledge Graph</i> (KG)	<i>Retrieval-Augmented Generation</i> (RAG), <i>Knowledge Graph</i> (KG), <i>Graph Neural Networks</i> (GNN)	Framework K-RagRec berhasil mengurangi halusinasi dan meningkatkan akurasi rekomendasi dibandingkan <i>vanilla</i> RAG
Enhancing E-commerce recommendations with sentiment analysis using MLA-EDTCNet and collaborative	Meningkatkan akurasi rekomendasi produk dengan mengintegrasikan analisis sentimen dan <i>Collaborative Filtering</i>	<i>Hybrid Deep Learning</i> (MLA-EDTCNet), <i>Modified Conditional GAN</i> (MCGAN) untuk <i>balancing</i> data, <i>Collaborative Filtering</i>	Model hibrida ini mengungguli model <i>state-of-the-art</i> dalam metrik akurasi, presisi, dan <i>recall</i> pada dataset produk Amazon, membuktikan efektivitas penggabungan sentimen dalam rekomendasi
Data augmentation for dense passage retrieval using corpus-passage frequency-based token deletion	Mengatasi ketidakseimbangan kelas pada <i>Dense Passage Retrieval</i> (DPR) untuk meningkatkan akurasi pencarian	<i>Dense Passage Retrieval</i> (DPR), <i>Corpus-Passage Frequency</i> (CPF) <i>token deletion</i>	Model hibrida ini mengungguli model <i>state-of-the-art</i> dalam metrik akurasi, presisi, dan <i>recall</i> pada dataset produk Amazon
Sentiment Analysis on Shopee Product Review using IndoBERT	Mengklasifikasikan sentimen ulasan produk Shopee berbahasa Indonesia	<i>Fine-tuning</i> model IndoBERT (BERT berbasis bahasa Indonesia)	Teknik <i>token deletion</i> berbasis frekuensi meningkatkan akurasi <i>Top-k</i> secara signifikan pada dataset kecil dan mempertahankan

	menggunakan model <i>pre-trained</i>		kinerja kompetitif pada dataset besar
A survey on retrieval-augmentation (RAG) models for healthcare applications	Mengkaji arsitektur RAG (Naive, Advanced, Modular) untuk aplikasi yang membutuhkan presisi tinggi dan minim halusinasi	Tinjauan sistematis arsitektur RAG dan evaluasi performa pada domain spesifik	IndoBERT mencapai akurasi maksimal hingga 93% dengan <i>batch size</i> 128, menunjukkan efektivitas model ini dalam memahami konteks ulasan berbahasa Indonesia
SEOpinion: Summarization and Exploration of Opinion from E-Commerce Websites	Meringkas opini berdasarkan aspek hierarkis dari ulasan dan detail produk <i>e-commerce</i>	<i>Web scraping</i> , <i>Hierarchical Aspect Extraction</i> (HAE), BERT <i>embedding</i> , RNN	<i>Modular RAG</i> memberikan fleksibilitas tertinggi dan akurasi superior untuk domain kompleks dibandingkan <i>Naive RAG</i> , serta efektif mengurangi halusinasi model generatif
Transoforming sentiment analysis for e-commerce product reviews: Hybrid deep learning model	Meningkatkan analisis sentimen ulasan produk menggunakan pembobotan istilah dan seleksi fitur yang inovatif	EGJO-LSTM (<i>Enhanced Golden Jackal Optimizer</i> - LSTM), LF-MICF <i>weighting</i>	Model RNN berbasis BERT menghasilkan performa terbaik dalam ekstraksi aspek dan peringkasan opini dibandingkan CNN dan SVM
IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding	Menyediakan <i>benchmark</i> dan model <i>pre-trained</i> (IndoBERT) untuk pemrosesan bahasa Indonesia	Pelatihan IndoBERT pada dataset masif Indo4B, evaluasi pada 12 tugas NLP	Algoritma EGJO-LSTM dengan pembobotan LF-MICF mencapai akurasi 97.65%, mengungguli metode konvensional dalam klasifikasi sentimen ulasan <i>e-commerce</i>
Transforming Sentiment Analysis for E-Commerce Product Reviews (Hybrid Model)	Menghasilkan ringkasan ulasan yang terpolarisasi (positif dan negatif) untuk membantu keputusan pembeli	<i>Graph-based summarization</i> (PageRank), GloVe <i>embeddings</i> , CNN	IndoBERT terbukti mengungguli model multilingual dalam berbagai tugas klasifikasi dan pemahaman bahasa Indonesia, menjadi fondasi kuat untuk pengembangan sistem NLP lokal
Polarized Extractive Summarization	Meningkatkan pencarian dan integrasi data	<i>Contextual Word Embeddings</i> (BERT,	Pendekatan ini berhasil memisahkan dan meringkas poin positif

of Online Product Reviews	berbentuk tabel/terstruktur menggunakan representasi vektor	RoBERTa), <i>Similarity Measure</i>	dan negatif secara akurat, membantu pengguna memahami kelebihan dan kekurangan produk dengan cepat
Contextual word embeddings for tabular data search and integration	Meningkatkan pencarian dan integrasi data berbentuk tabel/terstruktur menggunakan representasi vektor	Survei literatur sistematis tentang evolusi, teknik <i>retrieval</i> , dan <i>generation</i>	<i>Contextual embeddings</i> secara signifikan mengungguli model statis dalam pengambilan informasi, relevan untuk menangani data spesifikasi produk yang terstruktur
Retrieval-Augmented Generation for Large Language Models: A Survey	Memberikan tinjauan komprehensif tentang paradigma RAG untuk mengatasi keterbatasan LLM	<i>Eye-tracking experiment</i> , analisis perilaku konsumen	RAG secara efektif mengatasi masalah pengetahuan statis dan halusinasi pada LLM, dengan evolusi menuju <i>RAG modular</i> yang memungkinkan adaptabilitas lebih tinggi
The Impact of Online Reviews on Consumers Purchasing Decisions	Menganalisis bagaimana ulasan online mempengaruhi keputusan pembelian melalui atensi visual	<i>Eye-tracking experiment</i> , analisis perilaku konsumen	Konsumen, terutama wanita, memberikan perhatian visual lebih lama pada ulasan negatif, yang secara signifikan mempengaruhi keputusan pembelian mereka
Implementation of Deep Learning Models in Conducting Aspect-Based Sentiment Analysis	Membandingkan efektivitas model CNN dan LSTM untuk analisis sentimen berbasis aspek pada <i>e-commerce</i> Indonesia	<i>Deep Learning</i> (CNN vs LSTM), <i>Aspect-Based Sentiment Analysis</i> (ABSA)	Model LSTM menunjukkan kinerja yang lebih unggul (Akurasi 86.10%) dibanding CNN dalam menangkap konteks sekuensial dan struktur linguistik bahasa Indonesia
Recommender System in the Era of Large Language Models (LLMs)	Mengeksplorasi integrasi LLM ke dalam sistem rekomendasi untuk meningkatkan personalisasi	Tinjauan sistematis metode <i>LLM-based Recommendation</i>	LLM meningkatkan kemampuan sistem rekomendasi dalam hal pemahaman konteks dan <i>explainability</i> , terutama melalui teknik <i>prompting</i> dan <i>fine-tuning</i>

Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks	Memperkenalkan arsitektur RAG untuk tugas NLP yang membutuhkan pengetahuan eksternal	RAG (<i>Parametric + Non-parametric memory</i>), <i>Joint training</i>	RAG mencapai performa <i>state-of-the-art</i> pada <i>open-domain QA</i> , membuktikan bahwa menggabungkan <i>retrieval</i> dengan model generatif menghasilkan luaran yang lebih faktual dan spesifik
--	--	--	--

Sistem *Retrieval-Augmented Generation* (RAG) dirancang untuk mengatasi keterbatasan model bahasa besar (LLM) seperti halusinasi dan kurangnya pengetahuan terkini dengan menggabungkan kemampuan generatif dan pencarian informasi eksternal. Alur kerja sistem RAG dalam penelitian ini dimulai dengan fase pengumpulan dan pengolahan data. Data ulasan produk dan spesifikasi dikumpulkan dari *platform e-commerce* menggunakan teknik *web scraping* untuk mendapatkan data yang terstruktur seperti detail produk dan teks ulasan pelanggan (Mabrouk et al., 2021). Data teks mentah ini kemudian melalui tahap *preprocessing* yang meliputi pembersihan *noise*, tokenisasi, dan augmentasi data. Teknik augmentasi, seperti penghapusan token berbasis frekuensi korpus (*corpus-passage frequency*), diterapkan untuk meningkatkan kualitas representasi data dan mengatasi ketidakseimbangan kelas pada tahap *retrieval* selanjutnya (Moon et al., 2025).

Setelah data siap, proses berlanjut ke fase *indexing* dan representasi vektor. Dokumen ulasan dan informasi produk diubah menjadi representasi vektor padat (*dense vector representations*) menggunakan model *contextual word embeddings* seperti BERT. Penggunaan *embedding* kontekstual ini terbukti lebih unggul dibandingkan metode leksikal tradisional karena mampu menangkap makna semantik yang lebih dalam dari atribut tabel maupun teks ulasan (Pilaluisa et al., 2023). Representasi vektor ini kemudian disimpan dalam basis data vektor (*vector database*) yang memungkinkan pencarian semantik yang efisien. Untuk memastikan model memahami nuansa bahasa Indonesia dengan baik, digunakan model IndoBERT yang telah dilatih pada korpus masif bahasa Indonesia, yang terbukti memberikan performa tinggi dalam tugas klasifikasi teks dan pemahaman bahasa (Wilie et al., 2020; Aras et al., 2024).

Tahap inti dari sistem ini adalah fase *retrieval* dan *generation*. Ketika pengguna memasukkan pertanyaan atau permintaan rekomendasi, sistem melakukan pencarian (*retrieval*) pada basis pengetahuan untuk menemukan potongan informasi atau ulasan yang paling relevan. Proses *retrieval* ini krusial untuk memberikan konteks yang faktual bagi model generatif, sehingga mengurangi risiko halusinasi dan meningkatkan relevansi jawaban (Abo El-Enen et al., 2025; Lewis et al., 2020). Informasi yang ditemukan kemudian diintegrasikan dengan *knowledge graph* atau data terstruktur lainnya untuk memperkaya konteks sebelum diberikan kepada LLM (Wang et al., 2025). Terakhir, LLM menghasilkan ringkasan atau rekomendasi produk yang dipersonalisasi dengan menggabungkan preferensi pengguna dan sentimen dari ulasan yang telah dianalisis (Krishna et al., 2025). Luaran akhir sistem dapat berupa ringkasan

ekstraktif yang terpolarisasi, memisahkan poin positif dan negatif untuk membantu pengguna membuat keputusan pembelian yang lebih objektif (Devy et al., 2022).

BAB III
METODE PENELITIAN

3.1.3.1. Gambaran Umum Objek Penelitian

Metodologi penelitian ini dirancang secara sistematis melalui lima tahapan utama, yaitu *Data Gathering*, *Data Preprocessing*, *Model Selection*, *RAG Execution*, dan *Performance Evaluation*. Proses diawali dengan tahap *Data Gathering*, di mana dilakukan autentikasi terhadap Shopee Open Platform untuk memperoleh kredensial vital berupa *PartnerID*, *PartnerKey*, *ShopID*, *Access Token*, dan *Refresh Token*. Kredensial tersebut digunakan untuk mengakses tiga *endpoint* API spesifik yaitu *get item list*, *get item base info*, dan *get comment* guna mengakuisisi data produk dan ulasan yang kemudian dikonsolidasikan ke dalam format Excel. Data mentah tersebut selanjutnya memasuki tahap *Data Preprocessing* untuk dibersihkan dari nilai yang hilang (*missing values*), emoji, serta simbol non-alfanumerik yang tidak relevan. Pada tahap ini, diterapkan strategi *chunking* adaptif: informasi produk dipisahkan menjadi *chunk* independen, sementara ulasan dikategorikan berdasarkan panjangnya menjadi ulasan pendek dan panjang. Guna mengatasi keterbatasan *context window* pada model dan menjaga koherensi semantik, dilakukan injeksi

Formatted: Centered

Formatted: Font: (Default) Times New Roman, Bold

Formatted: Justified, Indent: First line: 1,27 cm, No bullets or numbering


Formatted: Font: (Default) Times New Roman, 12 pt

Formatted: Font: (Default) Times New Roman, 12 pt

Formatted: Font: (Default) Times New Roman, 12 pt

konteks dengan menyisipkan identitas produk ke bagian awal setiap *chunk* ulasan sebelum data tersebut di-embed dan disimpan ke dalam *vector database*.

Setelah tahap persiapan data selesai, penelitian berlanjut ke tahap *Model Selection* untuk menentukan model *embedding* dan *Large Language Model (LLM)* yang paling optimal. Model terpilih kemudian digunakan pada tahap *RAG Execution*. Dalam fase eksekusi ini, setiap *query* yang dimasukkan pengguna akan diproses melalui *embedding* untuk memicu pencarian (*retrieval*) dokumen yang relevan dari *vector database*. Hasil pencarian tersebut berfungsi sebagai konteks tambahan yang diteruskan kepada LLM bersama dengan pertanyaan pengguna untuk menghasilkan jawaban yang komprehensif. Rangkaian proses ini diakhiri dengan tahap *Performance Evaluation*, di mana kualitas jawaban yang dihasilkan oleh sistem dievaluasi secara objektif menggunakan metrik-metrik dalam kerangka kerja RAGAS (*Retrieval Augmented Generation Assessment*) untuk memastikan akurasi dan relevansi sistem.



Gambar 3.1.1 Metodologi Penelitian

3.2. Metode Penelitian

Metode Penelitian ini dirancang dengan alur yang sistematis untuk memastikan setiap tahapan, mulai dari pengambilan data hingga evaluasi, berjalan secara terstruktur. Secara garis besar, penelitian ini dimulai dengan tahap pengumpulan data yang berfokus pada pengambilan informasi produk beserta ulasannya langsung dari sumber menggunakan *API*. Setelah data terkumpul, proses berlanjut ke tahap analisis dan perancangan, di mana data teks *e-commerce* melewati *data cleaning* (pembersihan data) untuk menghilangkan data yang tidak digunakan dan menangani *missing value* (nilai yang tidak ada), lalu data akan melewati proses *chunking* (pemotongan data). Selanjutnya, penelitian masuk ke tahap implementasi teknis, yaitu pembangunan arsitektur RAG (*Retrieval-Augmented Generation*) yang menghubungkan basis

Formatted: Normal (Web), Justified

Formatted: Font: 10 pt, Not Bold

Formatted: Centered

Formatted: Justified, Indent: First line: 1,27 cm

data vektor dengan *Large Language Model* (LLM). Rangkaian proses ini kemudian ditutup dengan tahap evaluasi kinerja sistem, di mana kualitas jawaban yang dihasilkan oleh LLM akan dinilai menggunakan kerangka RAGAS (Retrieval Augmented Generation Assessment).

Formatted: Font: Not Bold

3.3. Metode Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan data yang diakuisisi langsung melalui Shopee Open Platform. Proses pengumpulan data diawali dengan melakukan autentikasi sistem untuk mendapatkan hak akses legal berupa *PartnerID*, *ShopID*, dan *Access Token*. Kredensial ini bertindak sebagai kunci untuk dapat berkomunikasi dengan server Shopee. Setelah akses terbuka, sistem akan memanggil serangkaian *API endpoints* secara berurutan. Langkah pertama adalah memanggil *get item list* untuk menarik daftar identitas seluruh produk yang ada di toko. Berbekal identitas tersebut, fungsi *get item base info* dijalankan untuk mengambil detail spesifik seperti judul, harga, dan deskripsi produk. Terakhir, dan yang paling penting untuk analisis sentimen, fungsi *get comment* dieksekusi untuk mengunduh ribuan ulasan pengguna terkait produk-produk tersebut. Seluruh data mentah yang berhasil ditarik ini kemudian digabungkan dan disimpan dalam format Excel agar mudah diolah pada tahap selanjutnya.

Formatted: Font: Not Bold

Formatted: Justified

Formatted: Font: Not Bold

3.4. Metode Analisis Data

Pada tahap analisis data, fokus utama adalah merancang logika bagaimana sistem "berpikir" untuk menemukan informasi yang relevan dan menyusun jawaban. Analisis dimulai dengan menyeleksi model *embedding* yang mampu menerjemahkan teks ulasan, yang seringkali menggunakan bahasa tidak baku atau *slang*, menjadi representasi vektor matematika yang akurat. Sistem kemudian dirancang untuk melakukan pencarian kemiripan (*similarity search*) di dalam basis data vektor, menggunakan algoritma seperti *Cosine Similarity* untuk menemukan potongan ulasan yang paling cocok dengan pertanyaan pengguna. Tidak berhenti di situ, hasil generasi jawaban dari LLM kemudian dianalisis kualitasnya menggunakan kerangka kerja RAGAS. Metode ini unik karena tidak membutuhkan kunci jawaban manual dari manusia, melainkan menggunakan LLM lain yang bertindak sebagai juri (*LLM-as-a-Judge*) untuk menilai apakah jawaban tersebut setia pada data fakta (*Faithfulness*), relevan dengan pertanyaan (*Answer Relevance*), dan apakah dokumen yang diambil benar-benar tepat sasaran (*Context Precision*).

Formatted: Font: Not Bold

Formatted: Justified

3.5. Metode Pengolahan Data

Sebelum data siap digunakan oleh model AI, data mentah harus melalui proses pengolahan yang cukup ketat. Tahap ini dimulai dengan *preprocessing*, yaitu membersihkan data dari elemen pengganggu seperti tag HTML, emoji, simbol aneh, dan spasi berlebih yang sering ditemukan pada deskripsi produk *e-commerce*. Penanganan data kosong juga dilakukan di sini untuk menjaga integritas sistem. Setelah data bersih, diterapkan strategi khusus yang disebut *Adaptive Chunking*. Berbeda dengan metode pemotongan teks biasa, strategi ini memisahkan perlakuan antara informasi produk dan ulasan. Ulasan yang sangat pendek akan dikelompokkan menjadi satu kluster sentimen, sedangkan ulasan panjang akan dipotong-potong secara bertahap (*batched chunking*). Guna mencegah hilangnya konteks saat

Formatted: Font: Not Bold

Formatted: Justified, Indent: First line: 1,27 cm

pemotongan, diterapkan teknik injeksi konteks (*Context Injection*), di mana nama produk secara otomatis disisipkan di awal setiap potongan ulasan. Dengan cara ini, meskipun ulasan dipotong, mesin tetap tahu ulasan tersebut merujuk pada produk apa sebelum akhirnya dikonversi menjadi vektor dan disimpan ke dalam *vector database*.

3.6. Studi Banding Obyek Penelitian Sejenis

Jika dibandingkan dengan penelitian-penelitian sebelumnya, kebanyakan sistem pencarian pada *e-commerce* masih mengandalkan metode berbasis kata kunci (*Keyword-Based Search*) atau *Lexical Search*. Kelemahan utama metode lama ini adalah ketidakmampuannya memahami konteks atau makna tersirat; jika pengguna menggunakan sinonim yang tidak ada dalam *database*, hasil pencarian seringkali nihil. Beberapa penelitian terbaru sudah mencoba menerapkan RAG standar, namun sering mengalami kegagalan konteks (*hallucination*) ketika berhadapan dengan data ulasan yang terfragmentasi dan tidak terstruktur. Penelitian ini menawarkan kebaruan (*novelty*) melalui pendekatan logika *Spatial-Temporal* dalam bentuk *Adaptive Chunking* dan injeksi konteks. Fokusnya bukan sekadar menemukan kata yang sama, melainkan memastikan bahwa setiap potongan data yang diambil oleh mesin memiliki konteks produk yang utuh. Hal ini diharapkan mampu menghasilkan sistem tanya-jawab yang jauh lebih cerdas, akurat, dan "manusiawi" dibandingkan metode pencarian konvensional yang ada saat ini.

Formatted: Font: Not Bold

Formatted: Justified

TINJAUAN PUSTAKA

- [1] Z. Syam, M. Arif, and A. Zulkarnaen, "SURVEI PENETRASI INTERNET DAN PERILAKU PENGGUNAAN INTERNET," 2025.
- [2] T. Chen, P. Samaranayake, X. Y. Cen, M. Qi, and Y. C. Lan, "The Impact of Online Reviews on Consumers' Purchasing Decisions: Evidence From an Eye-Tracking Study," *Front Psychol*, vol. 13, Jun. 2022, doi: 10.3389/fpsyg.2022.865702.
- [3] A. Mabrouk, R. P. D. Redondo, and M. Kayed, "Seopinion: Summarization and exploration of opinion from e-commerce websites," *Sensors (Switzerland)*, vol. 21, no. 2, pp. 1–25, Jan. 2021, doi: 10.3390/s21020636.
- [4] M. Varga and P. Albuquerque, "Measuring the Impact of a Single Negative Customer Review on Online Search and Purchase Decisions *," 2019. [Online]. Available: <https://ssrn.com/abstract=3483429>
- [5] H. Baars and H. G. Kemper, "Management support with structured and unstructured data - An integrated business intelligence framework," *Information Systems Management*, vol. 25, no. 2, pp. 132–148, Mar. 2008, doi: 10.1080/10580530801941058.
- [6] M. Abo El-Enen, S. Saad, and T. Nazmy, "A survey on retrieval-augmentation generation (RAG) models for healthcare applications," *Neural Comput Appl*, 2025, doi: 10.1007/s00521-025-11666-9.
- [7] S. Aras, M. Yusuf, R. Y. Ruimassa, E. A. B. Wambrauw, and E. B. Pala'langan, "Sentiment Analysis on Shopee Product Reviews Using IndoBERT," *Journal of Information Systems and Informatics*, vol. 6, no. 3, pp. 1616–1627, Sep. 2024, doi: 10.51519/journalisi.v6i3.814.

- [8] R. Punithavathi, M. Premkumar, G. Sinha, and K. Chandrasekaran, "Transforming sentiment analysis for e-commerce product reviews: Hybrid deep learning model with an innovative term weighting and feature selection," *Inf Process Manag*, vol. 61, no. 3, May 2024, doi: 10.1016/j.ipm.2024.103654.
- [9] G. M. S. Devy, K. Saideepthi, V. Sowmya, and R. Prasath, "Polarized Extractive Summarization of Online Product Reviews," in *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, Springer Science and Business Media Deutschland GmbH, 2022, pp. 147–160. doi: 10.1007/978-3-031-21517-9_15.
- [10] E. S. P. Krishna *et al.*, "Enhancing E-commerce recommendations with sentiment analysis using MLA-EDTCNet and collaborative filtering," *Sci Rep*, vol. 15, no. 1, Dec. 2025, doi: 10.1038/s41598-025-91275-7.
- [11] S. Wang *et al.*, "Knowledge Graph Retrieval-Augmented Generation for LLM-based Recommendation."
- [12] B. Wilie *et al.*, "IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding." [Online]. Available: <https://github.com/annisanurulazhar/absa-playground>
- [13] A. S. Moon, K. Kim, and J. Lee, "Data augmentation for dense passage retrieval using corpus-passage frequency-based token deletion," *J Big Data*, vol. 12, no. 1, Dec. 2025, doi: 10.1186/s40537-025-01257-9.
- [14] J. Pilaluisa, D. Tomás, B. Navarro-Colorado, and J. N. Mazón, "Contextual word embeddings for tabular data search and integration," *Neural Comput Appl*, vol. 35, no. 13, pp. 9319–9333, May 2023, doi: 10.1007/s00521-022-08066-8.
- [15] S. Minaee *et al.*, "Large Language Models: A Survey," Mar. 2025, [Online]. Available: <http://arxiv.org/abs/2402.06196>
- [16] Z. Wang, Y. Zhu, S. He, H. Yan, and Z. Zhu, "LLM for Sentiment Analysis in E-commerce: A Deep Dive into Customer Feedback," *Applied Science & Engineering Journal for Advanced Research Peer Reviewed and Refereed Journal ISSN*, pp. 8–13, 2024, doi: 10.5281/zenodo.12730477.
- [17] C. S. M. Ali and Dr. I. Mahmood Ibrahim, "A Comprehensive Survey on Large Language Models: Architectures, Applications, and Ethical Considerations," *Engineering and Technology Journal*, vol. 10, no. 04, Apr. 2025, doi: 10.47191/etj/v10i04.26.